

Consultor Especialista en Neuroanatomía
Sistema RAG – Flujo, Código Fuente y Ejecución de Consultas

Avance 2 — Desarrollo de Aplicaciones con Inteligencia Artificial

Viviana Marcela García Valderrama
Braian Felipe Ramírez Ortiz

Fundación Universitaria Konrad Lorenz
Facultad de Matemáticas e ingeniería
Desarrollo de Aplicaciones con Inteligencia Artificial
mayo de 2026
Bogotá D.C


1. Introducción

Este documento presenta la evidencia de ejecución del sistema RAG (Retrieval-Augmented Generation) implementado como Consultor Especialista en Neuroanatomía. El sistema lee artículos científicos en PDF, los vectoriza y permite consultas en lenguaje natural, respondiendo únicamente con información verificable de los documentos. La base vectorial se almacena en disco de forma local (ChromaDB + SQLite) preservando la privacidad de los datos.

2. Evidencia de Ejecución — Capturas de Pantalla

Las siguientes capturas muestran el sistema en funcionamiento real:

- 1. Sidebar con Lista base — 171 vectores indexados, 3 documentos y parámetros del motor***



2. Modelos 3D y RA con respuesta y fuente citada.



DESARROLLADO POR
Viviana García
Brisian Ramirez

Base de Conocimientos (3 documentos)

Agregar documentos PDF

Arrestar y suelta los archivos aquí
Límite de 200 MB por archi...
Explorar archivos

Documentos en la base

Regla Simple para el Ag...

Neurociencia Intermedia...

Modelos 3D y Realidad...

Parámetros del Motor

Argumentos a recuperar (4)

LLM: Gemini Flash

Recuperaciones generadas en el contexto (0)

Temperatura (0.1) | Fragmentos (0)

Lista base — 171 vectores indexados

RECONSTRUIR VECTORES

Asistente RAG fundamentado exclusivamente en literatura científica

7 Tu consulta científica

modelos 3D y RA con respuesta y fuente citada

ANALIZAR LITERATURA

Síntesis del Consultor

La creación de modelos anatómicos tridimensionales (3D) y de realidad aumentada (RA) se fundamenta en técnicas de fotogrametría, utilizando software automatizado como Autodesk ReCap Photo y semiautomatizado como 3Df Zephyr. Estas herramientas permiten obtener una mayor precisión anatómica en comparación con los especímenes cadavéricos de los animales, los cuales suelen presentar un deterioro significativo por el uso y el paso del tiempo.

En cuanto a la percepción de los residentes de neurocirugía sobre estos modelos, se reportan los siguientes hallazgos:

1. "Utilidad:" El 100% de los residentes considera que los modelos tridimensionales realizados mediante fotogrametría son útiles para el aprendizaje de la neuroanatomía.
2. "Comparación con modelos cadavéricos:" Al contrastar estas herramientas con los modelos cadavéricos, el 47.8% de los residentes considera que los modelos 3D y de RA son una peor herramienta, el 26% considera que no hay diferencia y el 21.7% opina que son una mejor herramienta.
3. "Eficacia del software:" No existe una diferencia significativa entre el uso de 3Df Zephyr y Autodesk ReCap Photo para la creación semiautomatizada de estos objetos anatómicos.
4. "Experiencia previa:" El 50% de los residentes ha utilizado previamente modelos 3D y de RA para su formación, mientras que un 11.1% manifestó que no los usaría para su entrenamiento.

Fuentes:

- ciruj_25_93_2_197-201.pdf, Pág. 0
- ciruj_25_93_2_197-201.pdf, Pág. 1
- ciruj_25_93_2_197-201.pdf, Pág. 2

1 piezas recuperadas

183 tokens de contexto

Detalles de Datos

Temperatura: 0.1

Evidencia Documental

Fragmento 1 — Modelos 3D y Realidad Aumentada en Neuroanatomía (Pág. 2)

Fragmento 2 — Modelos 3D y Realidad Aumentada en Neuroanatomía (Pág. 0)

Fragmento 3 — Modelos 3D y Realidad Aumentada en Neuroanatomía (Pág. 3)

Fragmento 4 — Modelos 3D y Realidad Aumentada en Neuroanatomía (Pág. 1)

3. Regla tres neuronas con respuesta estructurada.

DESARROLLADO POR

Viviana García

Brion Romínez

Base de Conocimientos (3 documentos)

Agregar documentos PDF

Aarrastra y suelta los archivos aquí

Límite de 200 MB por archi...

Explorar archivos

Documentos en la base

Regla Simple para el Ap...

Tecnologías Inmateriales

Medios 3D y Realidad

Parámetros del Motor

Fragmentos a recuperar (4)

1

LLM: Gemini Flash

Recatenciones: gema-embedding-0...

Temperatura: 0.2

Fragmentos: 100

Lista bona — 171 vectores indexados

CONSTRUIR VECTORES

Consultas Recientes

modelo 3D y 8d con respuesta y fun...

regla tres neuronas con respuesta estructurada

ANALIZAR LITERATURA

¿Cuáles son las estructuras neuroanatómicas estudiadas?

¿Qué metodología utilizaron los investigadores?

¿Qué hallazgos morfológicos se reportan?

¿Qué técnicas de imagen o histología se usaron?

Síntesis del Consultor

La regla de las "tres neuronas de los nervios aferentes" es una propuesta pedagógica diseñada para facilitar el aprendizaje lógico y sistemático de la neuroanatomía. A continuación se detalla su estructura y aplicación según los documentos científicos:

1. Definición y Patrón General

La regla establece un patrón constante para las vías aferentes donde se numeran intencionalmente la primera, segunda y tercera neurona. El principio general dicta que la "segunda neurona se decusa y llega al tálamo".

2. Estructuras y Vías de Aplicación

Esta sistematización se aplica a diversas conexiones neuronales, entre las que se incluyen:

- "Vías Somatosensoriales": Tracto espinotalámico y vía del lemnisco medial.
- "Nervios Craneales Sensoriales": Vía visual, tracto trigeminoespinotalámico, vía gustativa y vía auditiva.
- "Sistemas de Proyección y Regulación": Sistema de activación reticular ascendente, pontocerebelo (aférente al cerebro), núcleos basales (vía directa) y sistema límbico (circuito límbico medial).

3. Representación Gráfica

Para demostrar la regla en forma intuitiva, se utilizan dibujos consistentes donde:

- El "cerebro, el tálamo y el tronco encefálico" se representan como tres protuberancias (hinchazones).
- El "cerebelo" se representa como semicírculos al lado del tronco encefálico.

4. Excepciones y Limitaciones

El modelo reconoce que es una simplificación y presenta las siguientes salvaciones:

- "Decusación": En muchos casos, la segunda neurona puede no decusar.
- "Reconexión": Para mantener la simplicidad, se omiten sinapsis adicionales. Por ejemplo, en la vía auditiva, no se basta el núcleo del lemnisco lateral.
- "Necesidad de suplementación": Debido a su carácter simplificado para principiantes, la regla debe complementarse con contenidos detallados de neurofisiología, neurología y neurocirugía.

Fuente 0717-9502-journal-41-04-998.pdf, Pág. 0 y 5.

2 patrones recuperados

772 palabras de contexto

Positivo de Gálvez

Temperatura: 0.2


Evidencia Documental

Fragmento 1 — Regla Simple para el Aprendizaje de la Neuroanatomía (Pág. 5)

Fragmento 2 — Regla Simple para el Aprendizaje de la Neuroanatomía (Pág. 0)

Fragmento 3 — Regla Simple para el Aprendizaje de la Neuroanatomía (Pág. 5)

4. Metodología de investigación con citas de páginas.



3. Base de Conocimientos — Artículos Vectorizados

Se vectorizaron 3 artículos científicos en formato PDF generando 171 fragmentos indexados:

Archivo PDF	Título / Contenido
SCT_2025_1250.pdf	Tecnologías Inmersivas vs. Convencionales en la Enseñanza de Neuroanatomía — 10 págs.
0717-9502-ijmorphol-41-04-996.pdf	Regla Simple para el Aprendizaje Lógico de la Neuroanatomía — 7 págs.
circir_25_93_2_197-201.pdf	Modelos 3D y Realidad Aumentada en Neuroanatomía — 5 págs.
Total vectores	171 fragmentos · chunk_size=600 · overlap=80 · almacenados en ChromaDB

4. Flujo del Sistema RAG Implementado

4.1 Fase 1 — Indexación (Offline)

Paso	Descripción
PASO 1 – Carga	PyPDFLoader extrae texto página a página de cada PDF en Docs/
PASO 2 – Chunking	RecursiveCharacterTextSplitter · chunk_size=600 · overlap=80 caracteres
PASO 3 – Embeddings	gemini-embedding-2-preview · 3072 dimensiones · lotes de 50 con pausa anti-429
PASO 4 – Base vectorial	ChromaDB (SQLite) · colección: neuroanatomia_cientifica · similitud coseno · backup en ~/.neuro_db_permanent/

4.2 Fase 2 — Consulta (Tiempo Real)

Paso	Descripción
PASO 5 – Recuperación	Búsqueda semántica por similitud coseno · k=5 fragmentos (ajustable 3-8)
PASO 6 – Prompt aumentado	Contexto inyectado con etiquetas XML <contexto> + <pregunta>
PASO 7 – Generación LLM	REST API Gemini · fallback multi-modelo automático · temperature=0.1
PASO 8 – Presentación	Respuesta con citas de artículo y página

5. Código Fuente — System Prompt, Configuración y Formato de Salida

5.1 System Prompt (rag_pipeline.py, líneas 52–63)

SYSTEM_INSTRUCTION = ""Eres un consultor especialista en neuroanatomía con formación en investigación científica.

Tu misión es responder preguntas EXCLUSIVAMENTE basándote en el <contexto>.

REGLAS ESTRUCTURADAS (de mayor a menor prioridad):

1. Si la <pregunta> NO es científica, responde ÚNICAMENTE con:

"Por favor, formula una pregunta específica sobre los artículos científicos."

2. Si la respuesta NO está en el contexto, responde:

"Esta información no se encuentra en los documentos científicos disponibles."

3. Siempre cita la fuente (PDF y página) al final de la respuesta científica.

4. Usa terminología científica precisa. NUNCA uses conocimiento externo.

5. Si debes combinar fragmentos, intégralos de forma coherente.""

5.2 Prompt Template — Prompt Aumentado RAG (líneas 65–75)

PROMPT_TEMPLATE = ""

<contexto>

{context} ← k=5 fragmentos recuperados por similitud semántica

</contexto>

<pregunta>

{question}

</pregunta>

Responde EXCLUSIVAMENTE con el contexto. Cita artículo y página.""

5.3 Función consultar() — Configuración del Sistema (líneas 277–340)

```
def consultar(pregunta: str, vector_store: Chroma, k: int = 5) -> dict:

    # PASO 5 — Recuperación
    docs = vector_store.as_retriever(
        search_type="similarity", search_kwargs={"k": k}
    ).invoke(pregunta)

    # PASO 6 — Prompt aumentado con metadatos de fuente
    context = "\n\n---\n\n".join([
        f"[Fragmento {i} — {fuente}, Pág. {pagina}]\n{doc.page_content}"
        for i, doc in enumerate(docs, 1)
    ])

    # PASO 7 — Generación via REST (fallback multi-modelo)
    body = {
        "system_instruction": {"parts": [{"text": SYSTEM_INSTRUCTION}]},
        "contents": [{"parts": [{"text": PROMPT_TEMPLATE.format(...)}]},
        "generationConfig": {"temperature": 0.1, "maxOutputTokens": 2048},
    }

    # Intenta modelos en orden: gemini-2.0-flash-lite → gemini-2.0-flash
    #                               → gemini-flash-latest → gemini-2.5-flash

    # FORMATO DE SALIDA — diccionario estructurado
    return {
        "pregunta": pregunta,
        "respuesta": texto,      # Texto generado por el LLM
        "fragmentos": docs,      # Documentos recuperados
        "tokens_contexto_aprox": len(context)//4,
    }
```

5.4 Parámetros del Motor RAG

Parámetro	Valor / Justificación
chunk_size	600 caracteres — balance entre contexto y precisión
chunk_overlap	80 caracteres — continuidad entre fragmentos adyacentes
Modelo embeddings	gemini-embedding-2-preview — 3072 dimensiones, cupo independiente
Modelo LLM	gemini-flash-latest (+ fallback automático si hay 429)
temperature	0.1 — respuestas deterministas y reproducibles
max_output_tokens	2048 — respuestas completas sin truncar
k (recuperación)	5 — fragmentos por consulta (ajustable 3-8 en UI)
Similitud	Coseno — distancia semántica entre vectores
Base vectorial	ChromaDB (SQLite local) — colección: neuroanatomia_cientifica
Backup automático	~/.neuro_db_permanent/ — restauración sin re-vectorizar

6. Conclusiones

El sistema RAG implementado demuestra capacidad de respuesta científica precisa sobre neuroanatomía:

- Recupera fragmentos relevantes con alta precisión semántica (3072 dims de embedding)
- Cita correctamente las fuentes con nombre del artículo y página específica
- Rechaza preguntas fuera del dominio o sin respuesta en los 3 documentos
- Mantiene coherencia científica y terminología médica apropiada
- Opera completamente de forma local (ChromaDB SQLite) garantizando privacidad
- La DB se preserva automáticamente con backup en ~/.neuro_db_permanent/